NOMAD AI FACTORY · 실무 가이드

클로드 모델 역할분담 가이드

비싼 모델만 쓰면 토큰 낭비.
모델 6개를 직원 6명처럼 배치하는 법

오퍼스 5.5 · 팀장 | 페이블 5.1 · 자문위원 | 소네트 5.5 · 대리 | 하이쿠 · 막내 | 구버전 · 옛 직원

리치노마드 김대영 · 디지털노마드연구소
2026년 10월 8일 · 출처: 혼잡스 「클로드 모델 6개, 이 지도 한 장으로 끝내드립니다」 + Anthropic 공식 문서 검증

목차

01 개요 3

02 모델 6명 역할 지도 3

03 모델별 상세 4

- 오퍼스 5.5 — 팀장 4
- 페이블 5.1 — 외부 자문위원 4
- 소네트 5.5 — 대리 5
- 하이쿠 — 막내 5
- 구버전 모델 — 퇴직 앞둔 옛 직원 5

04 토큰 절약 3원칙 5

05 하루 일과 적용 예시 6

06 토큰이 새는 실수 3가지 7

07 Claude Code 실전 설정 7

08 공식 문서 대조 검증 8

09 사업 적용과 추천안 9

10 출처 10

01 개요

> **가장 비싼 모델을 쓰는 사람이 아니라, 일에 맞는 직원을 부르는 사람이 토큰을 아낀다.**

클로드 모델을 직원 6명으로 보고 일의 난이도에 따라 배정하면, 같은 결과를 몇 분의 1 비용으로 낼 수 있다.

- **출처**: 유튜브 채널 혼잡스, 「클로드 모델 6개, 이 지도 한 장으로 끝내드립니다 (비싼 것만 쓰면 토큰 낭비)」. Lilys AI 요약본 기준으로 정리했다.
- **검증**: 가격·기본값·명령어는 2026년 10월 8일 기준 Anthropic 공식 문서와 대조했다. 영상과 다른 부분은 08장에 따로 표시했다.
- **사용법**: 작업을 시작하기 전 3초만 "이 일, 막내한테 시켜도 되나?"를 묻는다. 그 질문 하나가 한 달 사용량을 바꾼다.

02 모델 6명 역할 지도

> **기본은 오퍼스 5.5, 매일 일은 소네트, 잡무는 하이쿠, 막혔을 때만 페이블.**

같은 일을 시켰을 때 영상 기준 비용은 하이쿠 1,000원 · 소네트 2,000원 · 오퍼스 4,000원 · 페이블 10,000원으로 최대 10배 차이가 난다.

모델	직급 비유	공식 가격 (입력/출력, $/MTok)	맡길 일	맡기지 말 일
오퍼스 5.5	팀장 (기본값)	$4 / $20	몇 시간짜리 코딩, 수십 개 파일 수정, 긴 문서 작업, 처음 해보는 큰 일	파일 찾기·이름 바꾸기 같은 잡무
페이블 5.1	외부 자문위원	$10 / $50	오퍼스가 못 푼 문제, 원인 불명 버그, 새 아키텍처 설계, 장시간 자율 작업	평소 일상 업무 (오퍼스의 2.5배 비용, 더 느림)
소네트 5.5	대리	$2 / $10	코드 수정, 글 초안, 표 정리, 자료 요약 등 이미 방법을 아는 매일 일	처음 해보는 큰 덩어리 작업

하이쿠 (영상 4.5 / 현재 5.5)	막내·심부름꾼	4.5: $1 / $5 5.5: $0.10 / $0.50	파일 찾기, 이름 바꾸기, 분류, 짧은 답장, 메일 분류	긴 판단·설계가 필요한 일
구버전 오퍼스 (5, 4.8 등)	퇴직 앞둔 옛 직원	$5 / $25	기존 시스템을 새 모델로 옮기는 동안만	새로 시작하는 모든 일 (신형보다 비쌈)
구버전 소네트 (4.6 등)	퇴직 앞둔 옛 직원	4.6: $3 / $15	위와 동일	위와 동일

하이쿠 5.5 가격은 프롬프트 10만 토큰 이하 기준. 출처: Anthropic 공식 가격표, 모델 개요.

03 모델별 상세

오퍼스 5.5 — 팀장

공식 문서도 "뭘 써야 할지 모르겠으면 오퍼스 5.5로 시작하라"고 권한다. 복잡하고 오래 걸리는 일을 혼자 끝까지 처리하며, Claude Code에서 Pro·Max·Team·Enterprise 모두 기본 모델이다.

- **빠른 모드(fast mode)**: 응답이 최대 약 2.5배 빨라지지만 가격은 2배($8 / $40)다. 마감이 코앞일 때만 쓴다.
- 기본 노력 수준은 이미 `medium`이다. 대부분의 일은 손대지 않아도 된다.

페이블 5.1 — 외부 자문위원

현재 쓸 수 있는 가장 똑똑한 모델이지만, 오퍼스보다 2.5배 비싸고 느리다. 팀장이 막혔을 때만 부르는 외부 전문가로 쓴다.

- 어떤 요금제에서도 기본 모델이 아니므로 `/model fable`로 직접 골라야 한다.
- 일부 요금제에서는 플랜 한도가 아니라 사용량 크레딧(usage credits)에서 차감된다. 선택 시 확인 창이 뜬다.
- 사이버보안·생물학 관련 요청은 안전 분류기에 걸리면 하위 모델(오퍼스 5, 4.8)로 자동 전환될 수 있다.
- 방법을 지시하기보다 원하는 결과를 말하고 맡기는 방식이 잘 맞는다.

소네트 5.5 — 대리

오퍼스의 절반 가격에 더 빠르다. 매일 하는 일 대부분은 이 모델로 충분하다. 처음 해보거나 덩어리가 큰 일은 오퍼스에, 방법을 이미 아는 일은 소네트에 맡긴다.

하이쿠 — 막내

여섯 명 중 가장 빠르고 싸다. 팀장이 큰 일을 하다가 "이 폴더에서 이 파일 좀 찾아와"라고 시키는 심부름꾼 역할이 분업의 핵심이다.

- **영상 기준 하이쿠 4.5**: 오퍼스의 1/4, 페이블의 1/10 가격, 기억력(컨텍스트)은 다른 모델의 1/5(20만 토큰).
- **현재 하이쿠 5.5**: 10만 토큰 이하 프롬프트 기준 입력 `$0.10`로 오퍼스 5.5의 1/40이고, 컨텍스트도 100만 토큰이다. 막내 활용 여지가 영상보다 훨씬 커졌다.

구버전 모델 — 퇴직 앞둔 옛 직원

구버전이 싸다고 생각하기 쉽지만 실제로는 더 비싸다. 오퍼스 5·4.8은 입력 $5로 오퍼스 5.5($4)보다 비싸고, 소네트 4.6은 $3로 소네트 5.5($2)보다 비싸다. 기존 프로그램을 새 모델로 옮길 시간을 벌기 위해 남겨둔 모델이므로, 새 작업에서는 고를 이유가 거의 없다.

04 토큰 절약 3원칙

> **노력 수준은 한 단계 낮춰 시작하고, 팀으로 나눠 시키고, 일 하나 끝내는 값으로 계산한다.**

1. 노력 수준(effort) 조절하기

같은 직원도 "대충 해줘"와 "꼼꼼하게 해줘"에 따라 걸리는 시간이 다르듯, 노력 수준에 따라 비용과 결과가 달라진다. 단계는 `low` · `medium` · `high` · `xhigh` · `max` 다섯 개다.

- 영상 소개 실험: 오퍼스 5.5 코딩 시험에서 노력 수준을 한 단계 낮추자 비용은 약 30% 줄고 점수는 2.5점만 떨어졌다.
- 조사·문서 작업은 낮춰도 정확도가 유지되는 경우가 많다.
- 더 좋은 방법: 낮은 단계로 먼저 돌리고, 실패한 작업만 높은 단계로 다시 돌린다.

- 설정: Claude Code에서 `/effort`. 한 번만 깊게 생각시키려면 프롬프트에 `ultrathink`를 넣는다.

2. 팀으로 나눠 시키기 (위임·분업)

비싼 직원은 계획만 세우고, 실제 작업은 싼 직원이 하게 한다.

- `opusplan`: 계획 모드에서는 오퍼스, 실행 단계에서는 소네트로 자동 전환된다.
- 서브에이전트: 찾기 담당은 하이쿠, 글 다듬기는 소네트, 검토는 오퍼스처럼 역할별 모델을 정의 파일에 한 줄로 지정해 둔다.
- 판단 기준: 서로 상관없는 작은 일이 여러 개면 나눠 맡기고, 하나로 길게 이어지는 일이면 한 모델에게 통째로 맡긴다. 분업에도 전달 비용이 들기 때문이다.

3. 일 하나 끝내는 값으로 계산하기

토큰 단가가 아니라 일을 완료하는 데 든 총비용으로 판단한다. 싼 모델이 여러 번 실수해 다시 시키게 되면, 비싼 모델로 한 번에 끝내는 쪽이 더 싸다. 결과를 다시 해야 하는 일일수록 한 번에 끝낼 수 있는 모델을 고른다.

05 하루 일과 적용 예시

> **네 모델을 일에 맞게 나눠 쓰면, 전부 페이블에 시킬 때보다 비용이 몇 분의 1로 줄어든다.**

시간대	할 일	배정 모델	이유
아침	메일 50통을 급한 것과 아닌 것으로 분류	**하이쿠**	빠르고 싸며, 틀려도 다시 보면 된다
오전	블로그 초안 작성, 매출표 정리	**소네트**	방법을 이미 아는 매일 일
오후	예약 받는 홈페이지 신규 제작 (파일 수십 개)	**오퍼스 5.5**	큰 덩어리 작업. 계획은 오퍼스, 구현은 소네트로 분업 가능
문제 발생	결제 버튼이 가끔 안 눌리는데 오퍼스도 원인을 못 찾음	**페이블 5.1**	팀장이 막혔을 때만 부르는 자문위원

06 토큰이 새는 실수 3가지

1. **주제가 바뀌었는데 같은 대화를 이어가기.** 클로드는 답할 때마다 이전 대화를 전부 다시 읽는다. 주제가 바뀌면 새 대화를 여는 쪽이 싸다.
2. **간단한 질문에 최대 노력 수준 쓰기.** "오늘 점심 뭐 먹지?"에 `max`를 거는 것은 팀장에게 회의 소집을 시키는 것과 같다.
3. **아끼려고 구버전 모델 고르기.** 구버전은 오히려 단가가 더 높다. 결과적으로 더 비싸게 먹힌다.

07 Claude Code 실전 설정

> **메인 세션은 오퍼스 또는 opusplan, 반복 잡무는 하이쿠 서브에이전트로 고정하는 것이 가장 효과가 크다.**

하고 싶은 것	방법
모델 바꾸기	`/model sonnet` · `/model opus` · `/model haiku` · `/model fable` 선택은 다음 세션 기본값으로 저장됨. 피커에서 `s`는 이번 세션만
계획은 오퍼스, 실행은 소네트	`/model opusplan`
노력 수준 바꾸기	`/effort low` ~ `/effort xhigh`. `max`는 현재 세션에만 적용
한 번만 깊게 생각시키기	프롬프트에 `ultrathink` 포함
빠른 모드	`/fast` (오퍼스 계열, 단가 2배)
서브에이전트 기본 모델 일괄 지정	환경변수 `CLAUDE_CODE_SUBAGENT_MODEL=haiku`
과부하 시 대체 모델	`claude --fallback-model sonnet,haiku`
현재 모델 확인	`/status`

역할별 서브에이전트 예시

`.claude/agents/` 폴더에 역할마다 파일 하나를 두고, `model`과 `effort`를 지정한다.

```
---
name: file-finder
description: 코드베이스에서 파일·심볼 위치를 찾을 때 사용
tools: Glob, Grep, Read
model: haiku
effort: low
---
찾은 파일 경로와 한 줄 근거만 반환한다. 파일 내용 전체를 붙이지 않는다.
```

```
---
name: reviewer
description: 구현이 끝난 변경사항을 검토할 때 사용
tools: Read, Grep, Glob, Bash
model: opus
effort: high
---
버그, 엣지 케이스, 보안 문제만 우선순위 순으로 보고한다.
```

주의: `/model` 로 메인 모델을 바꾸면 모델을 따로 지정하지 않은 서브에이전트도 함께 바뀐다. 잡무 에이전트는 반드시 `model` 을 명시해 둔다.

08 공식 문서 대조 검증

> **영상의 큰 틀은 공식 문서와 일치한다. 단, 하이쿠는 5.5가 나오면서 영상보다 훨씬 싸고 강해졌다.**

영상 내용	공식 문서 (2026-10-08)	판정
가격 비율 하이쿠 1 : 소네트 2 : 오퍼스 4 : 페이블 10	입력 단가 하이쿠 4.5 $1, 소네트 5.5 $2, 오퍼스 5.5 $4, 페이블 5.1 $10	**일치 (하이쿠 4.5 기준)**
막내는 하이쿠 4.5, 컨텍스트 1/5	하이쿠 5.5 출시. 입력 $0.10(10만 토큰 이하), 100만 토큰 컨텍스트. Claude Code `haiku` 별칭도 v2.1.293부터 5.5	**업데이트 필요**
모르겠으면 오퍼스 5.5로 시작	공식 모델 개요의 권장 문구와 동일	**일치**
오퍼스 5.5가 Claude Code 기본 모델	Pro·Max·Team·Enterprise·API 모두 기본 오퍼스 5.5	**일치**

페이블은 기본 모델 아님, 직접 선택	어떤 요금제에서도 기본 아님. 일부 플랜은 사용량 크레딧 차감	**일치 + 보완**
빠른 모드는 가격 2배	오퍼스 5.5 빠른 모드 $8 / $40	**일치**
구버전이 오히려 비쌈	오퍼스 5·4.8 $5, 소네트 4.6 $3. 단 소네트 5는 소네트 5.5와 같은 $2	**대체로 일치**
opusplan, 서브에이전트별 모델 지정	`opusplan` 별칭, 서브에이전트 `model` · `effort` 필드 존재	**일치**

영상에 없지만 알아둘 것

- 오퍼스 5.5·소네트 5.5·하이쿠 5.5의 기본 노력 수준은 이미 `medium`이다. 공식 테스트에서 오퍼스 5.5 `medium`이 오퍼스 5 `high`와 같거나 더 낫다.
- 하이쿠 5.5는 프롬프트가 10만 토큰을 넘으면 단가가 5배(`$0.50 / $2.50`)가 된다. 막내에게는 짧은 일을 준다는 원칙이 여전히 유효하다.
- 프롬프트 캐시 적중 시 오퍼스·소네트 5.5는 입력 단가의 5%, 페이블 5.1은 2.5%만 낸다. 같은 대화를 짧게 이어갈 때는 캐시 덕에 비용이 크게 줄어든다.
- 급하지 않은 대량 처리는 Batch API로 입력·출력 모두 50% 할인된다.
- 영상의 실험 수치(노력 수준별 점수·비용 변화)는 요약본에서 옮긴 것이라 원문 스크립트로 한 번 더 확인하는 것을 권한다.

09 사업 적용과 추천안

> **추천: 개발 환경에 역할별 서브에이전트부터 고정하고, 같은 원칙을 운영 중인 SaaS의 API 호출과 강의 콘텐츠로 확장한다.**

적용 영역	실행 방법	기대 효과	난이도
개발 (Claude Code)	찾기·정리는 하이쿠, 구현은 소네트, 검토는 오퍼스 서브에이전트 3종 템플릿을 모든 프로젝트에 복사	한도 소진 속도 감소, 메인 컨텍스트 절약	낮음
SaaS API 비용	블로그·쇼폼·커머스 자동화의 분류·태깅·추출 단계를 하이쿠 5.5로, 생성은 소네트 5.5로 나누는 라우터 계층	분류 단계 단가 최대 1/40, 마진 개선	중간

대량 작업	급하지 않은 콘텐츠 생성은 Batch API로 묶어 처리	해당 작업 50% 절감	중간
콘텐츠·강의	이 지도를 1페이지 치트시트로 만들어 바이브코딩 강의 리드마그넷, 「모델 라우팅으로 토큰 절반 줄이기」 강의 모듈	신규 수강생 유입, 전자책 챕터 재활용	낮음
신규 SaaS 아이디어	팀 단위 Claude 사용 로그를 받아 "이 작업은 하이쿠로 충분했다"를 알려주는 비용 진단 도구	1인 개발자·에이전시 대상 소규모 구독	높음 (검증 먼저)

린 검증 순서

- ☐ 이번 주: 서브에이전트 3종 적용 전후로 일주일 사용량을 `/status` 와 비용 기록으로 비교
- ☐ 치트시트를 랜딩페이지 리드마그넷으로 올리고 다운로드 수 확인
- ☐ 반응이 있으면 강의 모듈 제작, 비용 진단 도구는 노코드 설문·수동 리포트로 먼저 5명에게 판매 테스트

10 출처

- 혼잡스, 「클로드 모델 6개, 이 지도 한 장으로 끝내드립니다」 — youtu.be/dmmaZeEwlJ4 (Lilys AI 요약본 기준)
- Anthropic Models overview — platform.claude.com/docs/en/models/overview
- Anthropic Pricing — platform.claude.com/docs/en/about-claude/pricing
- Claude Code Model configuration — code.claude.com/docs/en/model-config